

摘要

本报告对大语言模型（LLM）后训练技术进行了全面综述，涵盖三个关键领域：微调（Fine-tuning）、对齐（Alignment）和评测框架（Evaluation Harness）。我们考察了从全量微调到参数高效方法（如 LoRA 和 QLoRA）的演进，调研了包括 RLHF、DPO 和 GRPO 在内的对齐技术，并回顾了用于评估 LLM 能力的主要评测框架。

关键词：大语言模型、微调、LoRA、QLoRA、RLHF、DPO、GRPO、评测框架

1. 微调（Fine-tuning）

1.1 什么是微调？

微调是在预训练模型基础上，使用较小的、任务特定的数据集继续训练的过程。其目标是将模型的通用知识适配到特定领域或任务，而无需承担从头训练的高昂成本。预训练 LLM 已经学习了丰富的语言表征——句法、语义、世界知识和推理模式。微调调整这些表征以在目标任务上表现更好。

1.2 预训练 vs 微调 vs 指令微调

方面	预训练	微调	指令微调
目标	下一个token预测	任务特定损失	响应生成
数据	大规模无标注文本	任务特定标注数据	指令-响应对
规模	数十亿token	数千到数百万	数千到数百万
算力	数千GPU小时	数小时到数天	数小时到数天

1.3 全量微调 vs 参数高效微调

全量微调更新所有模型参数，对于 7B 参数模型需要约 60-80 GB GPU 显存。参数高效微调（PEFT）仅更新一小部分参数，主要包括 LoRA、QLoRA、Prefix Tuning、Adapter Tuning 等方法。

1.4 LoRA：低秩适配

LoRA 基于以下观察：微调过程中的权重更新往往具有低内在秩。将更新分解为两个低秩矩阵： $W' = W + \Delta W = W + B \times A$ ，其中 $A \in \mathbb{R}^{(r \times d)}$ ， $B \in \mathbb{R}^{(d \times r)}$ ，秩 $r \ll d$ 。对于 $d=4096$ ， $r=16$ ：仅需更新 13.1 万参数，而非 1670 万参数。

1.5 QLoRA：量化 LoRA

QLoRA 将 4 位量化与 LoRA 结合：（1）4 位 NormalFloat（NF4）量化；（2）双重量化；（3）分页优化器。使得在单块 48GB GPU 上微调 65B 模型成为可能。

1.6 方法对比

方面	全量微调	LoRA	QLoRA
可训练参数	100%	~0.1-1%	~0.1-1%
GPU显存 (7B)	~60 GB	~16 GB	~6 GB
训练速度	基准	快1.2-1.5倍	0.8-1.0倍
性能	最佳	全量微调的98%	全量微调的95%

最低GPU	A100 80GB	RTX 3090 24GB	T4 16GB
-------	-----------	---------------	---------

2. 对齐（Alignment）

2.1 什么是对齐？

对齐是指确保语言模型的行为与人类价值观和意图保持一致的过程。目标是产生有帮助（Helpful）、无害（Harmless）、诚实（Honest）的模型。预训练模型针对下一个 token 预测优化，而非成为有帮助的助手。

2.2 RLHF：基于人类反馈的强化学习

RLHF 是主流的对齐范式，应用于 InstructGPT、ChatGPT 和 Claude。包含三个阶段：

- 阶段 1：监督微调（SFT）- 在高质量指令-响应对上微调
- 阶段 2：奖励模型（RM）训练 - 人类标注者排序，训练奖励模型
- 阶段 3：PPO 优化 - 使用奖励模型优化策略

2.3 DP0：直接偏好优化

DP0 通过直接在偏好数据上优化策略，消除了对独立奖励模型的需求。关键洞察是 RLHF 下的最优策略具有闭式解。相比 RLHF：无需奖励模型、无需 RL 训练循环、更简单稳定、计算成本更低。

2.4 GRPO：群组相对策略优化

GRPO 是 DeepSeek-R1 中使用的较新对齐方法，通过移除评论家/价值模型简化 PPO。对每个提示采样 G 个响应，通过组内归一化计算优势。优势：无需价值模型（节省约 50% 显存），对推理任务有效。

2.5 对齐方法对比

方法	奖励模型	RL训练	复杂度	最佳适用
RLHF/PP0	是	是	高	通用对齐
DP0	否	否	低	离线偏好
RLAIF	AI 评判	否	低	可扩展对齐
GRPO	否	简化	中	推理任务

3. 评测框架（Evaluation Harness）

3.1 什么是评测框架？

评测框架是一个标准化系统，用于在多个基准测试、任务和指标上系统地评估语言模型。它提供一致性、可复现性、可比性和自动化能力。

3.2 常见基准测试

基准测试	能力	语言	指标
MMLU	知识 (57学科)	英文	准确率
He l l aSwag	常识推理	英文	准确率
ARC	科学问答	英文	准确率
GSM8K	数学推理	英文	准确率

HumanEval	代码生成	Python	Pass@k
C-Eval	中文知识	中文	准确率

3.3 评测框架对比

框架	开发者	任务数	中文基准	易用性
lm-eval-harness	EleutherAI	200+	有限	高
OpenCompass	上海AI实验室	100+	强	中
HELM	Stanford CRFM	42场景	有限	中

3.4 lm-evaluation-harness 使用

```
lm_eval --model hf \
  --model_args pretrained=MODEL_NAME \
  --tasks mmlu,hellaswag \
  --device cuda:0 \
  --batch_size 8
```

4. 后训练流程

完整的 LLM 后训练流程：预训练模型 → 监督微调（SFT）→ 偏好数据收集 → 对齐训练（RLHF/DPO/GRPO）→ 评测（lm-eval-harness/OpenCompass/HELM）→ 基准测试结果与错误分析。每个阶段建立在前一阶段的基础上，逐步将原始语言模型转变为有能力、安全且可靠的助手。

5. 结论

本综述涵盖了 LLM 后训练的三大支柱：

- 1. 微调将预训练模型适配到特定任务，LoRA 和 QLoRA 以最小成本实现了高效适配
- 2. 对齐确保模型按照人类价值观行事，DPO 为传统 RLHF 提供了更简单的替代方案
- 3. 评测框架为衡量模型能力提供了标准化系统

该领域正在快速发展，GRPO 等新方法正在推动对齐技术的边界，特别是在推理任务方面。

参考文献

[1] Hu et al., "LoRA: Low-Rank Adaptation of Large Language Models", 2021

[2] Dettmers et al., "QLoRA: Efficient Finetuning of Quantized LLMs", 2023

[3] Ouyang et al., "Training language models to follow instructions with human feedback", 2022

[4] Rafailov et al., "Direct Preference Optimization", 2023

[5] Shao et al., "DeepSeekMath: Pushing the Limits of Mathematical Reasoning", 2024

[6] Taori et al., "Stanford Alpaca", 2023

[7] Liang et al., "Holistic Evaluation of Language Models (HELM)", 2022

- [8] Hendrycks et al., "Measuring Massive Multitask Language Understanding (MMLU)", 2021
- [9] Gao et al., "lm-evaluation-harness", 2023
- [10] Vaswani et al., "Attention Is All You Need", 2017